

UT3

Computer Vision

Fundamentos del Aprendizaje Automático

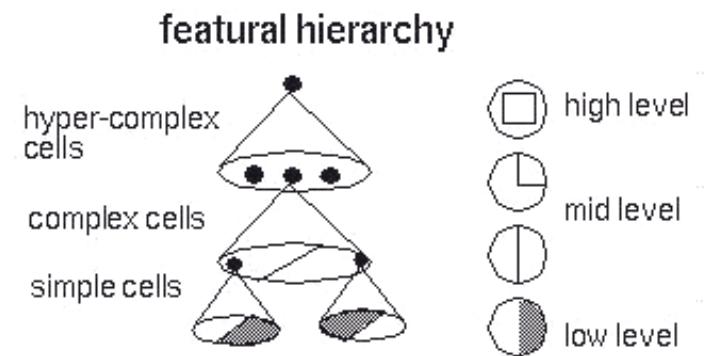
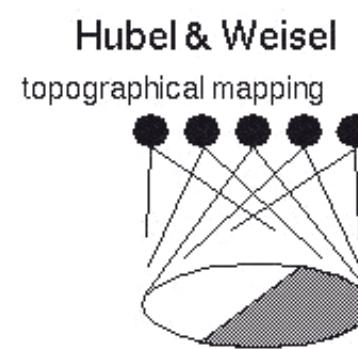
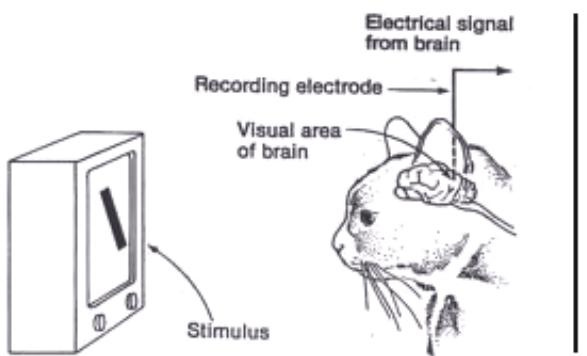
Profesor: Ing. Juan Francisco Kurucz

juan.kurucz.sosa@ucu.edu.uy



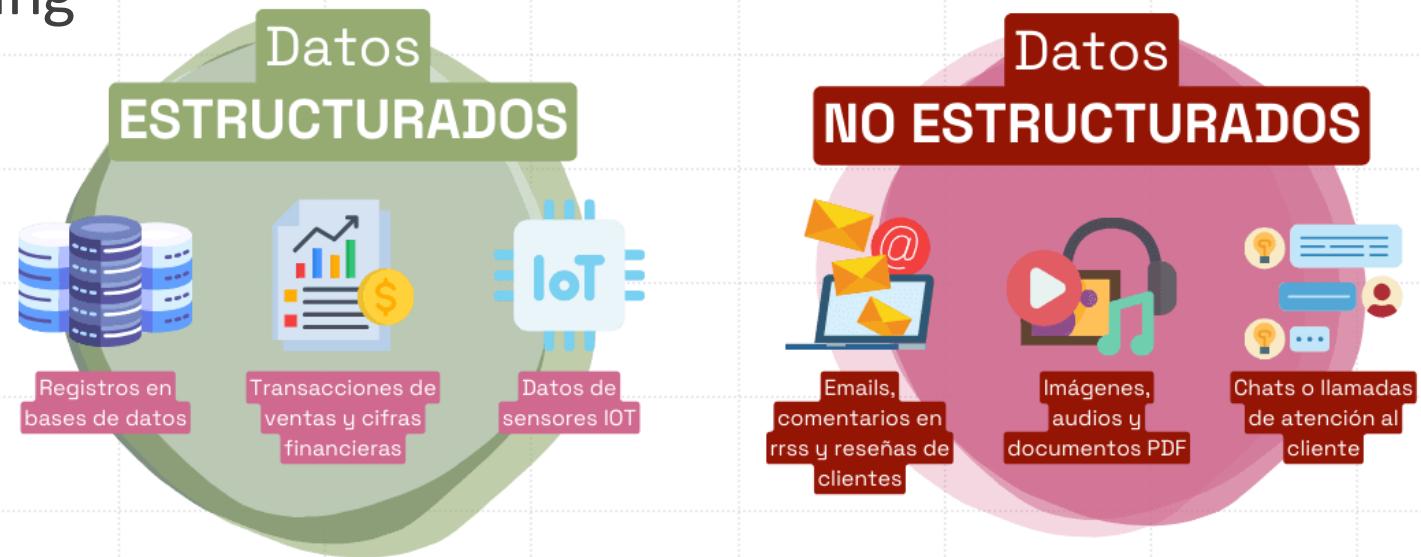
Corteza visual

- Hubel & Wiesel (1959 y 1962)
- Organización jerárquica
 - Células simples
 - Células complejas
 - Células hipercomplejas



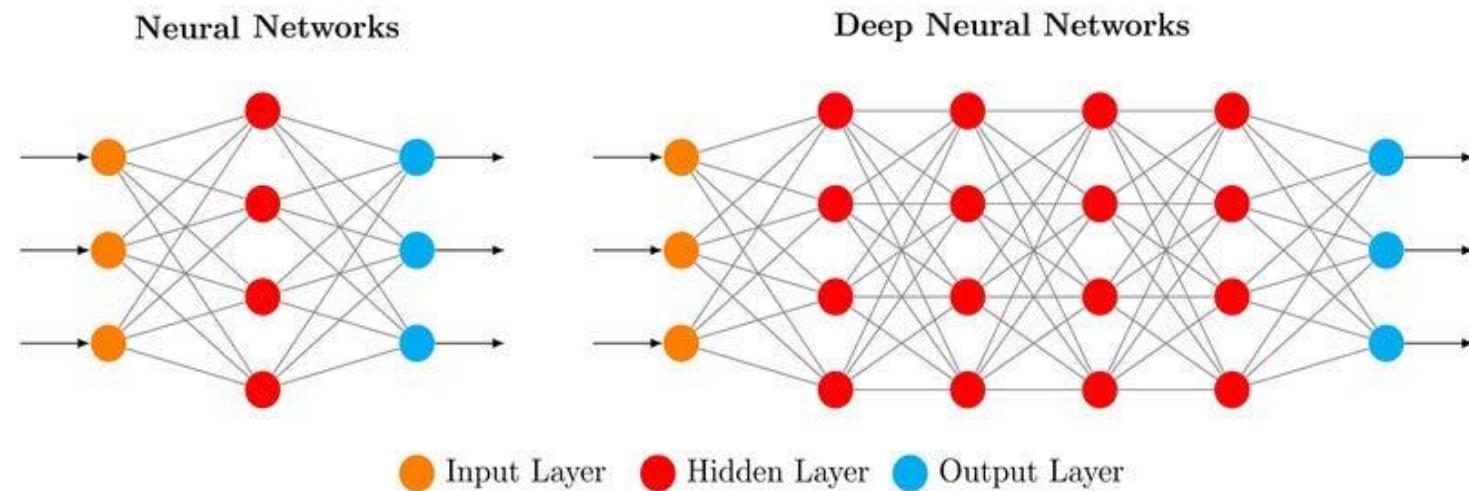
Deep Learning

- 2 clases de datos:
 - Datos estructurados (tablas, CSV): Feature extraction
 - Datos no estructurados (imágenes, sonidos, texto): Representation learning



Deep Learning - DNN

- Múltiples capas
- Cada capa aprende una forma distinta de representación
- Características jerarcas

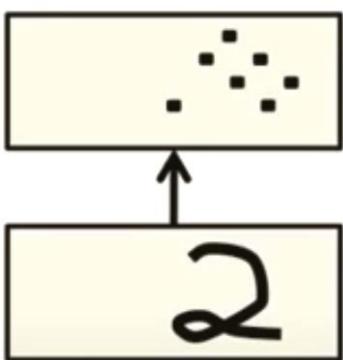
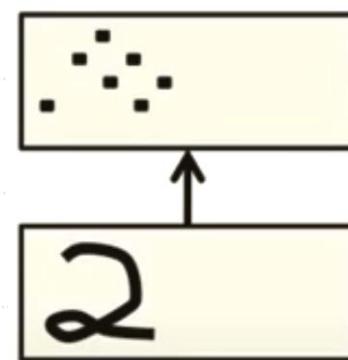


Problemas Redes Neuronales comunes

- Cada neurona pondera todas las entradas
- Cantidad de parámetros
 - Entrada: imagen $32 \times 32 \times 3$
 - 3072 conexiones por neurona!!
- Información local

Características replicadas

- En una imagen los objetos pueden aparecer en diferentes partes
- Reutilizar detectores de características en mas de una posición
 - Reduce los parámetros para aprender
- Conocimiento invariante



Representación de imágenes

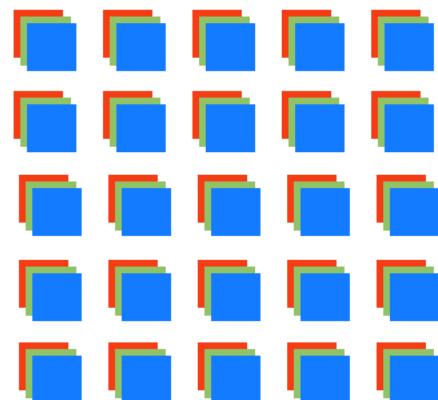


Each pixel value



r,g,b

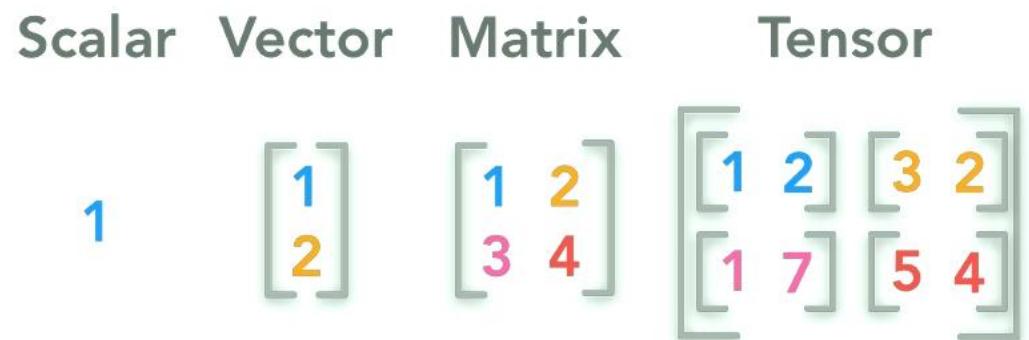
Tensor of image



400x300x3

Tensor

- Estructura de datos muy usada en Machine Learning y Deep Learning
- Arreglo multidimensional
 - Orden 0: Escalar
 - Orden 1: Vector
 - Orden 2: Matriz
 - Orden n: Tensor



Desafíos de imágenes

Viewpoint variation



Scale variation



Deformation



Occlusion



Illumination conditions



Background clutter

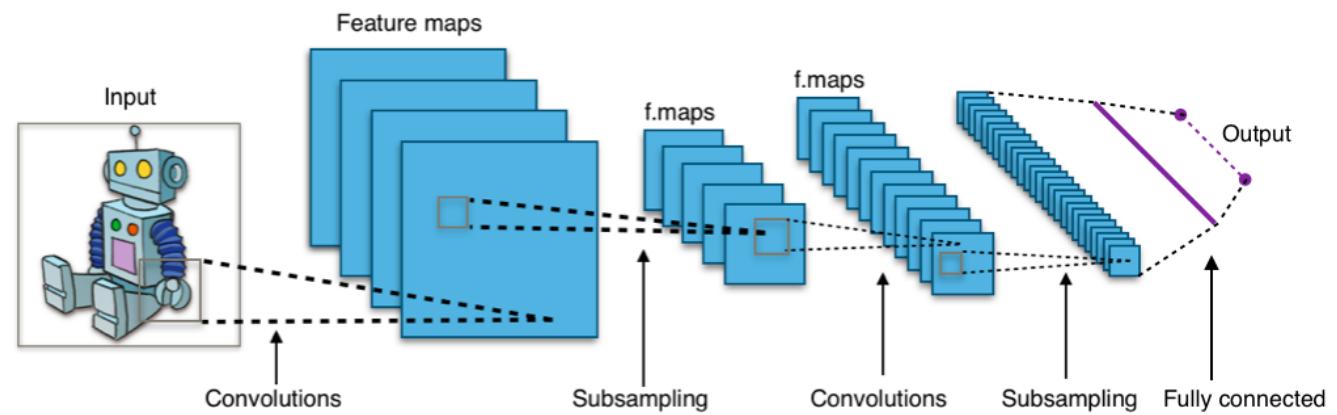


Intra-class variation



Redes Neuronales Convolucionales (CNN)

- Especializadas para el reconocimiento de patrones complejos
- Exitosas para problemas de Computer Vision
 - Reconocimiento de objetos, caras, etc
- Procesamiento de todo tipo de señales
 - Imágenes
 - Audio
 - Video
 - Medicina



Convolución

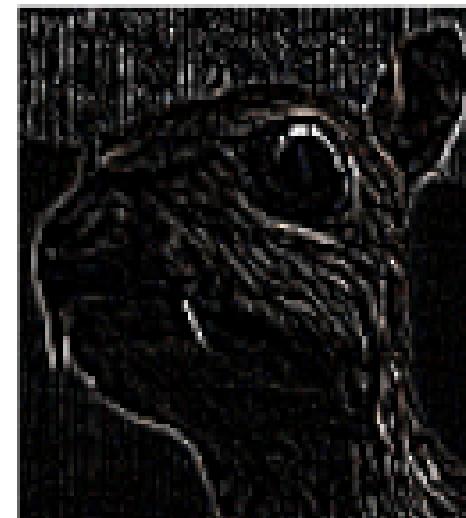
Input image



Convolution
Kernel

$$\begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$$

Feature map

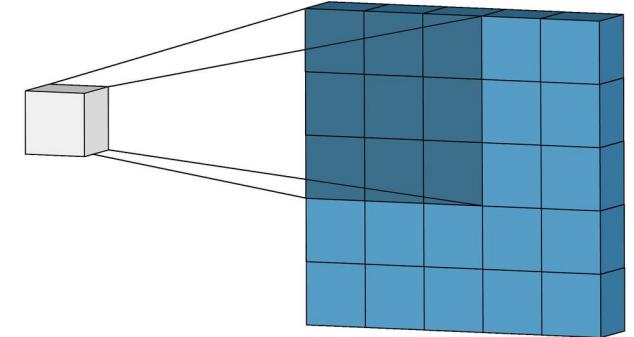


<https://setosa.io/ev/image-kernels/>

Filtro o Kernel

- Extraer características de la entrada
- Detección de patrones
 - Bordes
 - Esquinas
 - Figuras
 - Objetos
 - Etc
- Cuanto mas profunda es la red, mas sofisticados son los filtros.

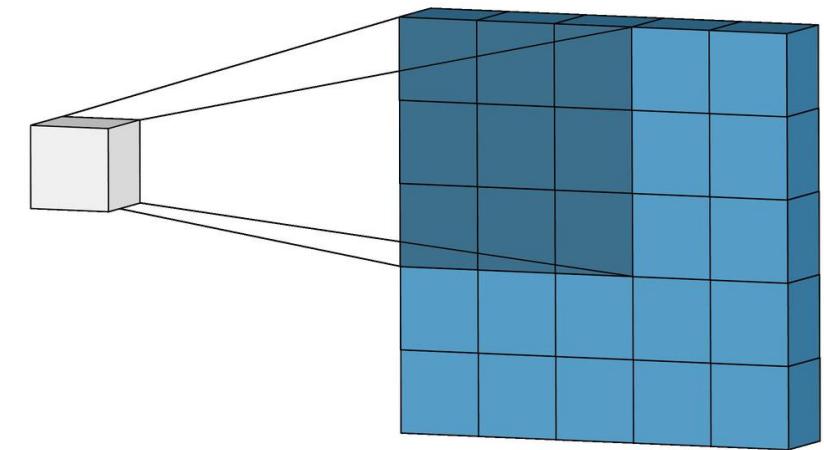
Filtros - funcionamiento



- Ventana pequeña
- Matriz de tamaño definido
- Se va “desplazando” por los valores de entrada
- Operación de convolución

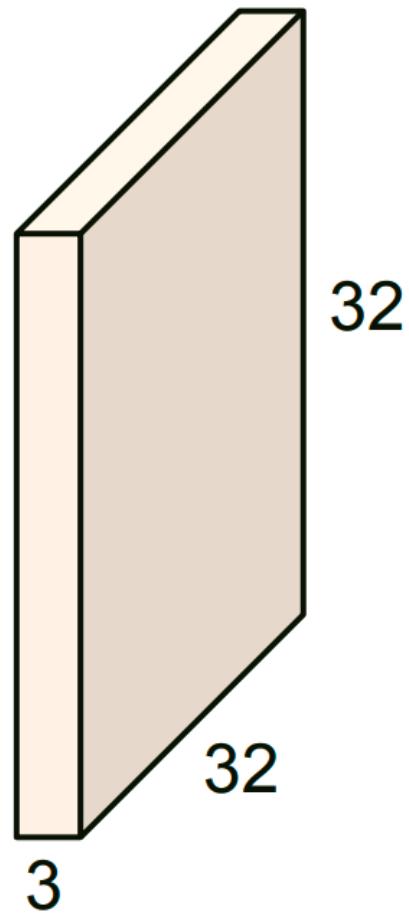
Capa convolutiva

- Compuesta de unidades convolutivas (filtros)
- Los pesos de las neuronas son los valores del filtro
- Varios filtros por capa convolutiva

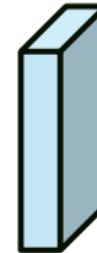


Capa convolutiva

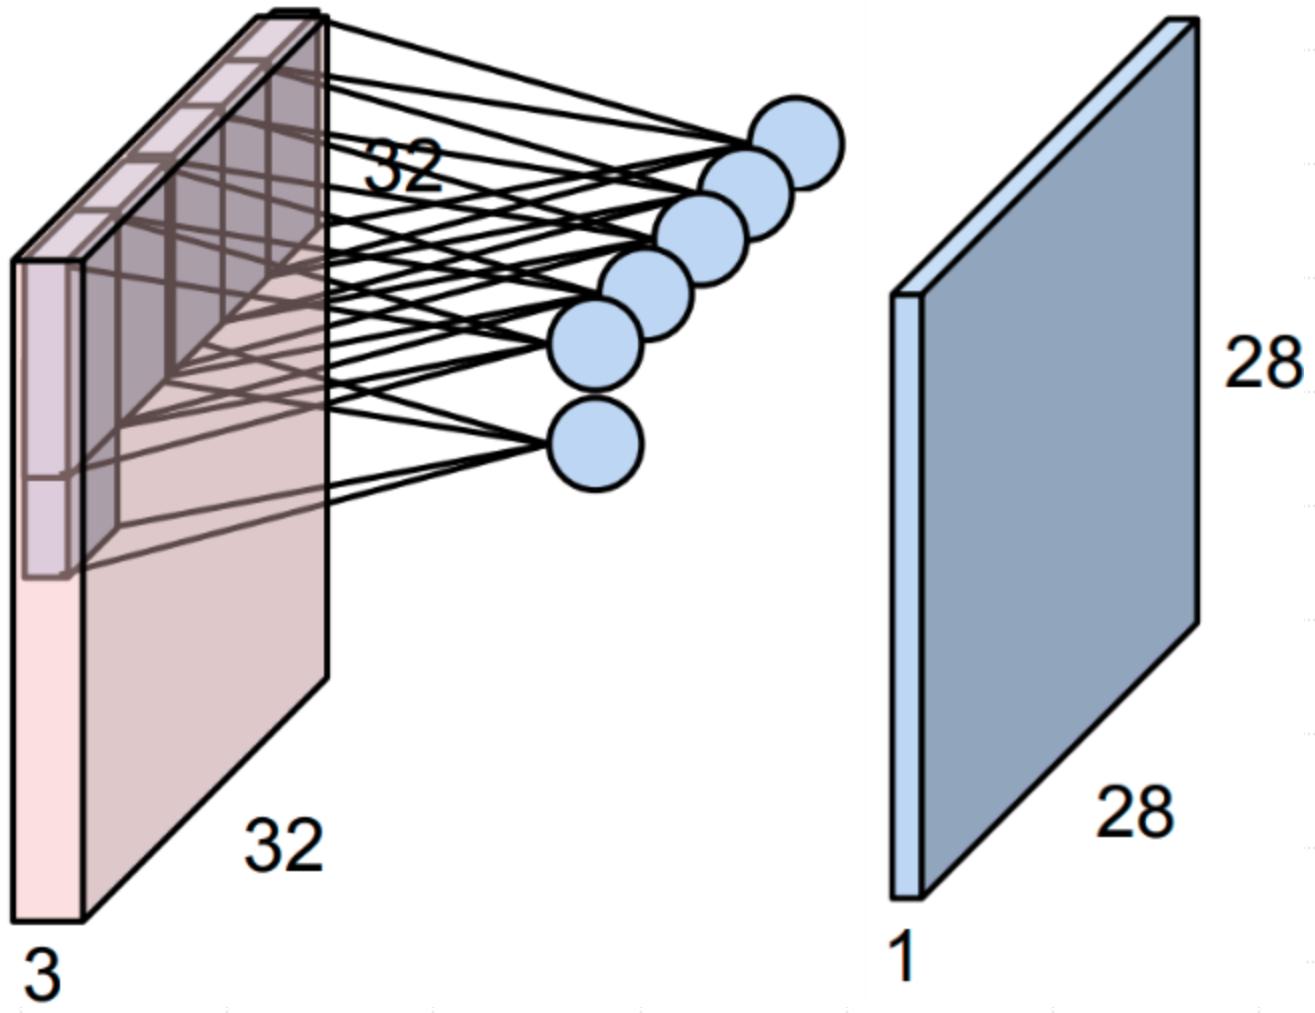
32x32x3 image



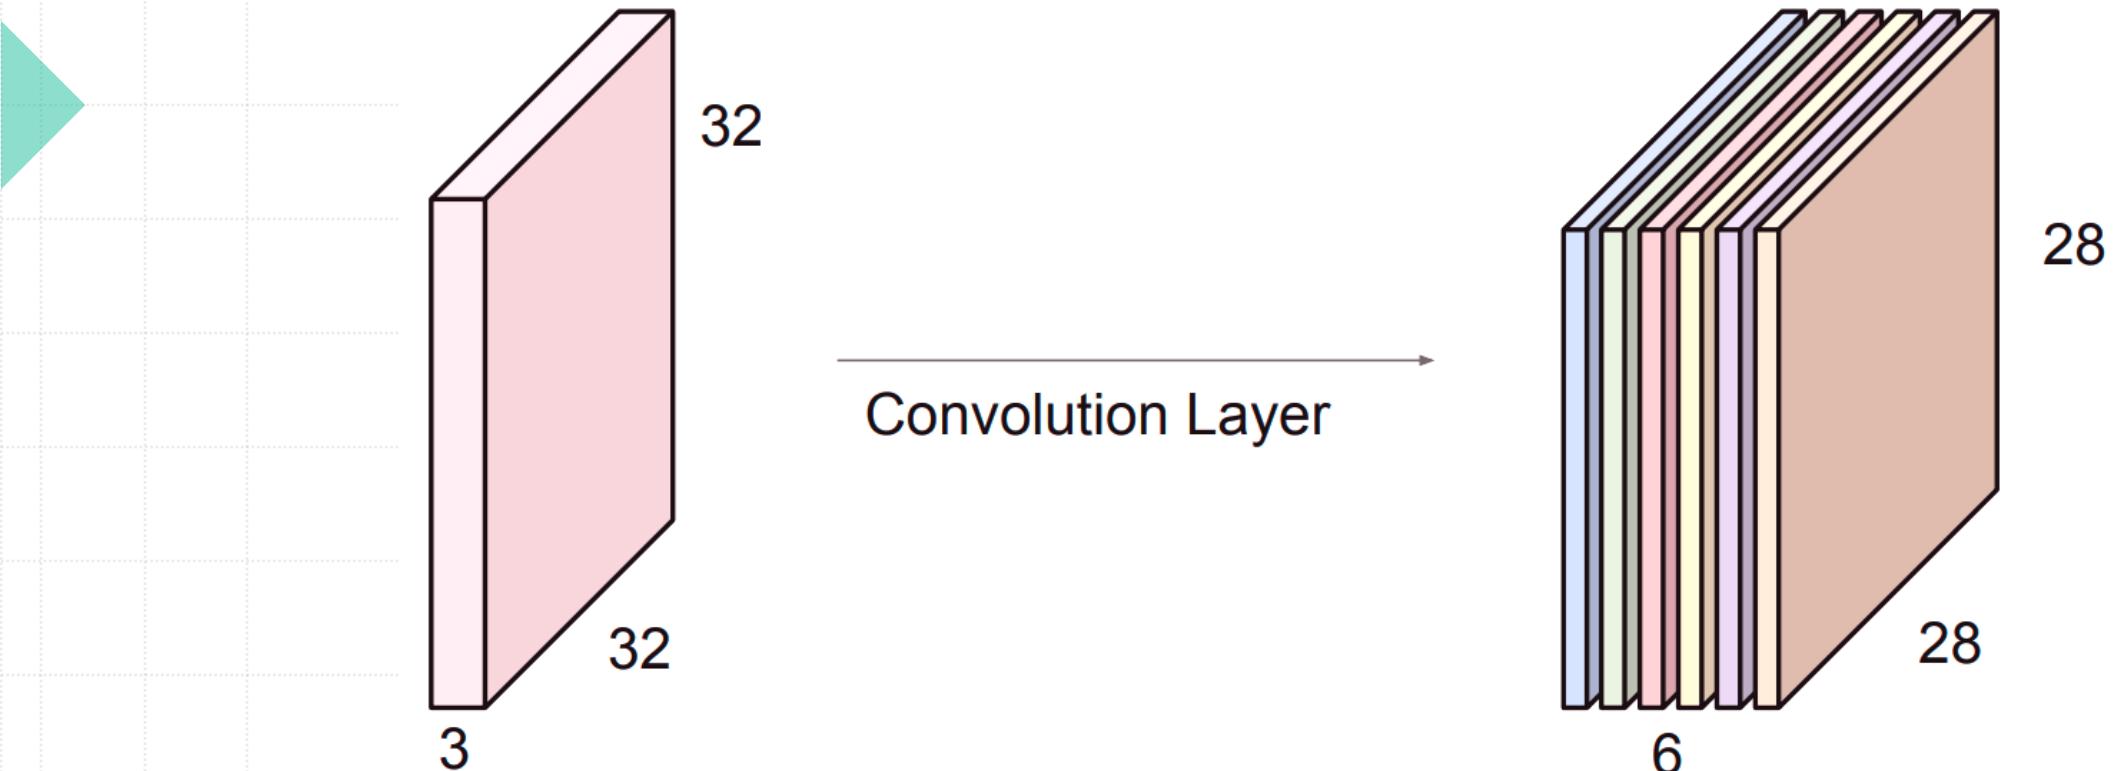
5x5x3 filter



Capa convolutiva



Capa convolutiva



Con 6 filtros de $5 \times 5 \times 3$

¿Cuántos parámetros (w) hay en la capa?

NN vs CNN – Cantidad de Parámetros

Imagen 32x32x3

NN

- Cada neurona conecta con todas las anteriores
- $32 \times 32 \times 3 = 3.072$ parámetros por cada neurona en la capa
- Con 100 neuronas son **307.200**

CNN

- 6 filtros de 5x5
- $5 \times 5 \times 3 \times 6 = 450$ parámetros para toda la capa

Padding



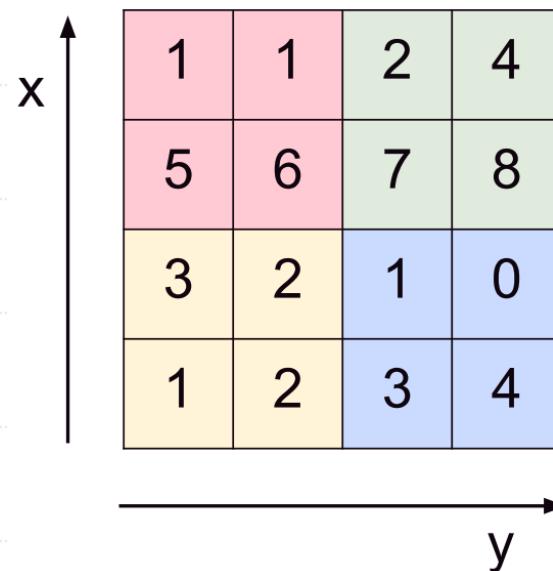
0	0	0	0	0	0		
0							
0							
0							
0							

Hiperparametros CNN

- Cantidad de filtros o kernels
- Tamaño del filtro o kernel
- Desplazamiento del filtro o Stride
- Padding

Capa de pooling

- Muestreo
- Sirve para condensar la información
- Tipos
 - Max pooling
 - Average pooling
- Etc
- Previene variaciones en la posición de las características
- Reduce la memoria



max pool with 2x2 filters
and stride 2

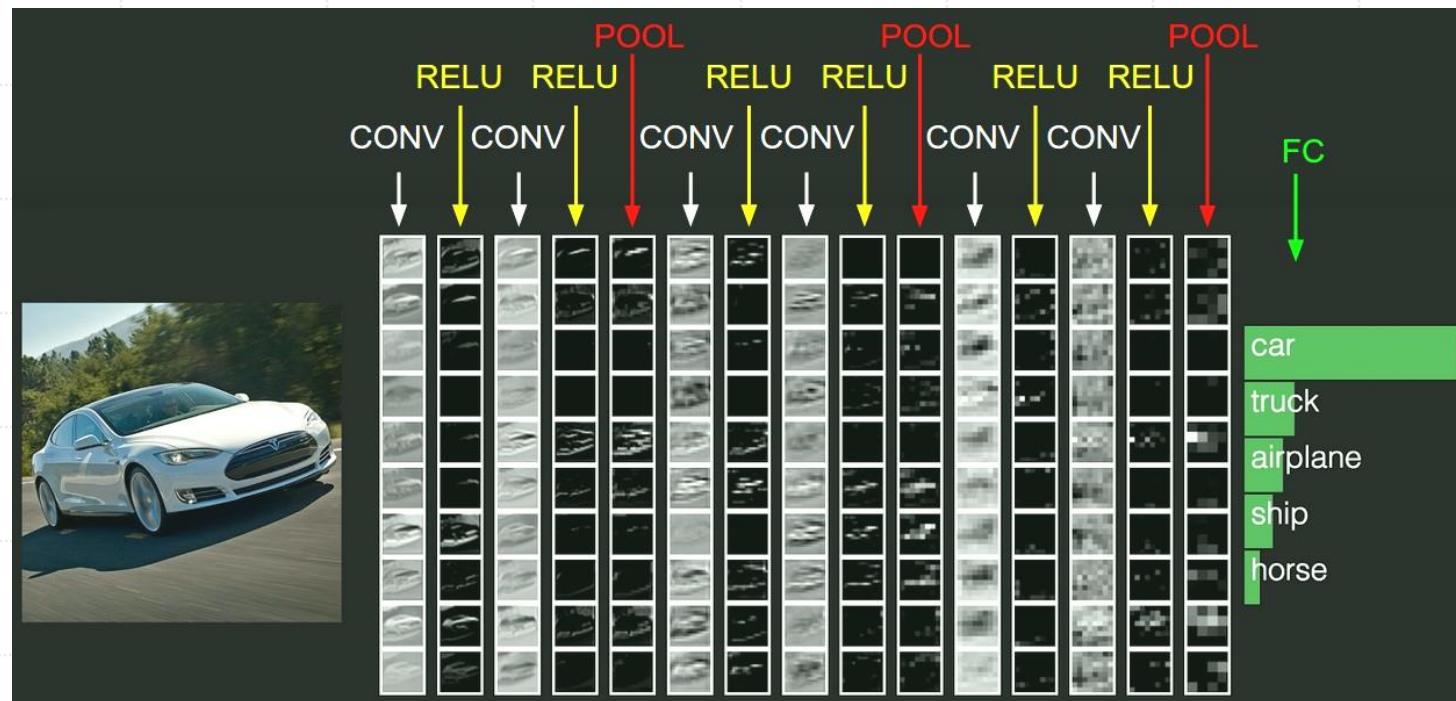
The result of the max pooling operation is a 2x2 output feature map. The values are:

6	8
3	4

The output values are determined by taking the maximum value from each 2x2 receptive field in the input. For example, the top-left cell of the output has a value of 6, which is the maximum of the top-left 2x2 subgrid in the input.

Estructura CNN

- Combinación de capas convolucionales y pooling
- Detección de clases al final (red FC)



Ejemplo: LeNet (Yann LeCun 1998)

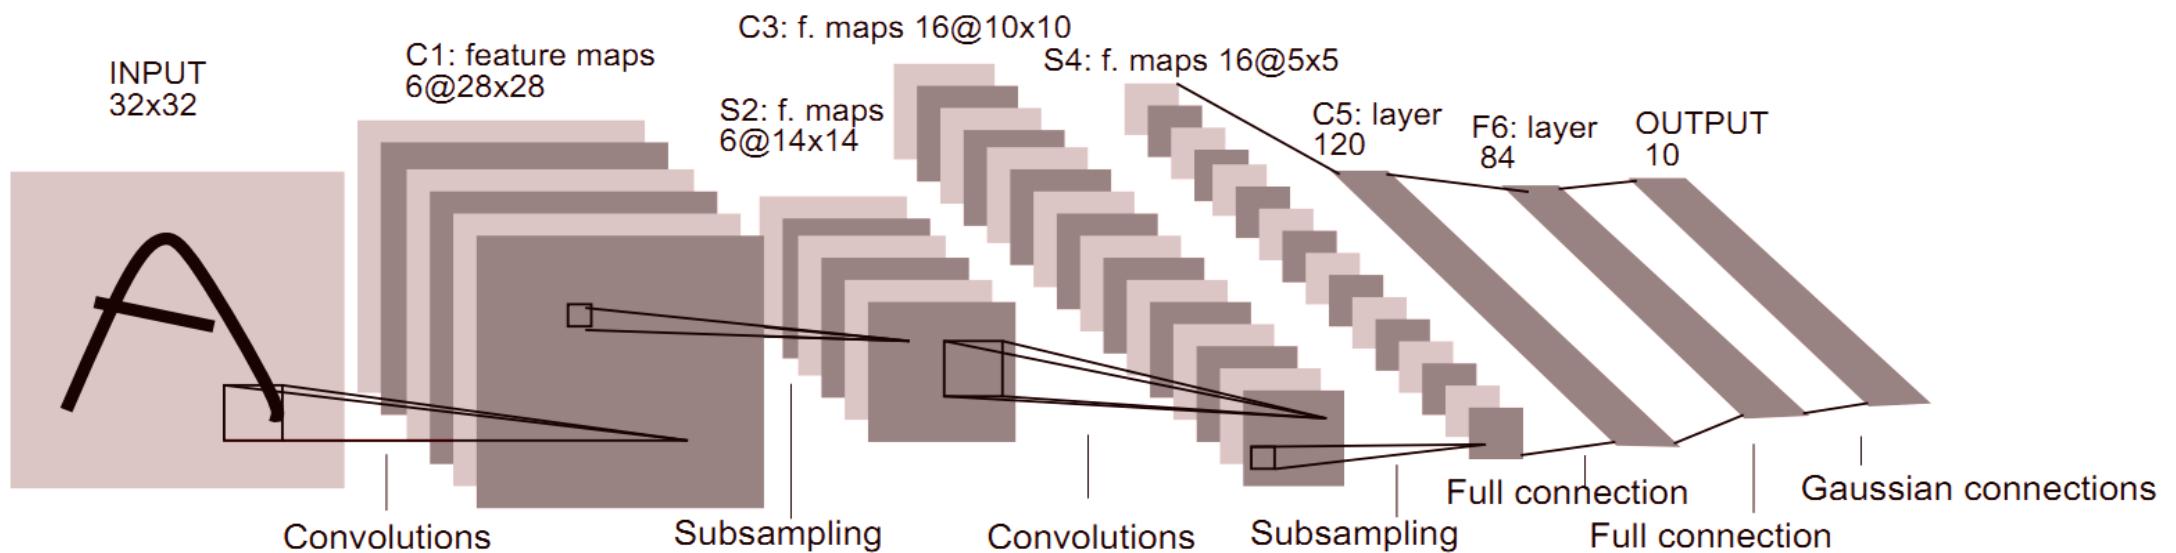
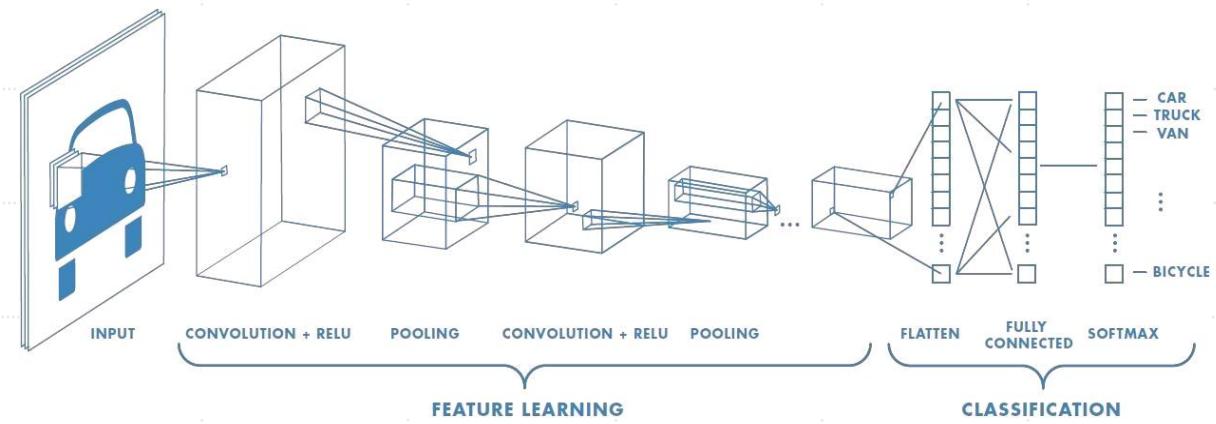


Fig. 2. Architecture of LeNet-5, a Convolutional Neural Network, here for digits recognition. Each plane is a feature map, i.e. a set of units whose weights are constrained to be identical.

Estructura CNN

- Primeras capas
 - características primitivas (bordes, contrastes, etc)
- Últimas capas
 - características más complejas, abstractas y específicas (formas, objetos, texto, etc)



Transfer Learning



El entrenamiento de una red neuronal requiere:

- Muchos datos disponibles y relevantes
- Gran poder de computo
- Tiempo

Solución:

- usar un modelo ya entrenado y adaptarlo a otro problema

Transfer Learning



Es necesario:

- remplazar capas del final con nuevas
- usar la red ya entrenada para la extracción de características
- entrenar solamente los parámetros de las capas nuevas

Transfer Learning

- Feature extraction:
 - Usar un modelo pre entrenado y adaptarlo agregando una capa de clasificación.
 - Se re usan los pesos del modelo base
 - Solo se entrena el clasificador
- Fine-Tuning:
 - Volver a entrenar las capaz superiores del modelo base junto con las capaz nuevas

Transfer Learning – “Model Zoo”

Model	Size	Top-1 Accuracy	Top-5 Accuracy	Parameters	Depth
Inception-ResNet-V2	215 MB	0.804	0.953	55,873,736	572
Xception	88 MB	0.79	0.945	22,910,480	126
Inception-v3	92 MB	0.788	0.944	23,851,784	159
DenseNet-201	80 MB	0.77	0.933	20,242,984	201
ResNet-50	99 MB	0.759	0.929	25,636,712	168
DenseNet-169	57 MB	0.759	0.928	14,307,880	169
DenseNet-121	33 MB	0.745	0.918	8,062,504	121
VGG-19	549 MB	0.727	0.91	143,667,240	26
VGG-16	528 MB	0.715	0.901	138,357,544	23
MobileNet	17 MB	0.665	0.871	4,253,864	88

Transfer Learning - Limitaciones

- No siempre se puede transferir conocimiento de un modelo a otro
 - Tipos de datos totalmente distintos: imágenes, audio, etc.
 - Arquitectura totalmente diferente

Data Augmentation

- Técnica para mejorar los resultados y prevenir overfitting
- Expandir el dataset creando versiones modificadas de las imágenes
- Transformaciones sobre las imágenes:
 - shift, flip, rotation, brightness, zoom, etc

